

Carro Autônomo em Pistas: Neural Network and Machine Learning Integration

Alano Baptista - 20190818
Luqueunia Galiano - 20210451

Keywords—*Algoritmo NEAT, Evolução de Controladores, Eficiência de Redes Neurais*

I. RESUMO

Este artigo apresenta uma abordagem para enfrentar o desafio de corridas autônomas usando redes neurais evolutivas em um ambiente simulado com três pistas distintas inspiradas na Fórmula 1. O algoritmo evolutivo NEAT é utilizado para evoluir controladores de redes neurais adaptados a cada pista, resultando em comportamentos adaptativos e eficientes. O estudo fornece uma análise detalhada do desempenho dos controladores em cada contexto único.

O processo de experimentação envolveu ajustes em parâmetros-chave dentro do algoritmo NEAT, impactando significativamente a velocidade de aprendizado e adaptabilidade dos controladores evoluídos. Ajustes notáveis incluem a otimização das taxas de mutação para ativação de neurônios e habilitação de conexões, o uso de elitismo em estratégias de reprodução, e a configuração cuidadosa das camadas e neurônios ocultos da rede neural.

Esses refinamentos não apenas aceleraram o processo de aprendizado, mas também aprimoraram a adaptabilidade dos controladores evoluídos às nuances específicas de cada pista.

II. INTRODUÇÃO

Nos últimos anos, o campo de veículos autônomos tem experimentado avanços notáveis, impulsionados por desenvolvimentos em técnicas evolutivas e redes neurais. Este estudo focaliza a evolução de controladores inteligentes para um carro de corrida simulado, explorando os desafios apresentados por três pistas distintas. A escolha por simulações oferece um ambiente controlado e uma análise aprofundada do comportamento dos controladores.

O diferencial deste trabalho reside na implementação de redes neurais evolutivas, combinadas com o algoritmo NEAT (NeuroEvolution of Augmenting Topologies), para enfrentar os desafios das pistas, cada uma inspirada nas complexidades da Fórmula 1.

As pistas proporcionam uma diversidade de desafios, incluindo curvas fechadas, retas de alta velocidade e variações abruptas de terreno. Ao explorar esses cenários, busca-se a evolução de estratégias adaptativas que se destacam em contextos diversos.

A evolução dos controladores não se limita apenas à otimização de parâmetros; ela engloba a personalização dinâmica da arquitetura da rede neural, permitindo uma adaptação contínua às especificidades de cada pista. Dessa forma, este estudo contribui para aprimorar a eficiência dos veículos autônomos em ambientes de corrida, oferecendo insights sobre a capacidade de adaptação de sistemas inteligentes a cenários complexos e variados..

III. METODOLOGIA

• Ambiente de Simulação:

Cada pista é tratada como um ambiente de simulação independente, incorporando características específicas. A adaptação a cada pista é essencial, exigindo repetição do processo de aprendizagem para otimização em contextos diferentes.

• Algoritmo Genético e Redes Neurais:

O algoritmo NEAT é configurado para otimizar controladores de redes neurais adaptados a cada pista, ajustando dinamicamente a topologia da rede neural para atender às demandas específicas de cada ambiente.

• Sensores e Funcionamento:

Sensores virtuais são empregues para captar informações sobre a proximidade das bordas da pista, permitindo à rede neural tomar decisões informadas sobre direção, aceleração e desaceleração.

IV. RECOMPENSA E FUNCIONAMENTO

A recompensa é atribuída com base na distância percorrida e no tempo decorrido, incentivando comportamentos eficientes. Penalidades são aplicadas por curvas bruscas, promovendo estratégias de navegação mais suaves.

V. COMPOSIÇÃO E FUNCIONAMENTO DA REDE NEURAL

A rede neural evoluída possui uma arquitetura dinâmica, adaptando-se ao longo das gerações. Os sensores virtuais alimentam a entrada da rede, enquanto a saída determina as ações do carro. A função de ativação tangente hiperbólica (tanh) proporciona uma resposta não linear.

VI. Melhorias e Ajustes no Desempenho do Algoritmo NEAT:

Durante o processo de experimentação e otimização, identificamos algumas configurações chave no algoritmo NEAT que influenciaram significativamente o desempenho dos controladores evoluídos para corridas autônomas. Estas modificações não apenas aceleraram a aprendizagem, mas também aprimoraram a adaptabilidade dos controladores a ambientes específicos. Algumas dessas modificações notáveis incluem:

- Taxa de Mutação da Ativação dos Neurônios:

activation_mutate_rate = 0.05

Ajustar a `activation_mutate_rate` revelou-se crucial para a velocidade de aprendizagem. Um aumento nessa taxa acelerou a adaptação dos controladores, permitindo uma resposta mais rápida às mudanças nas condições da pista.

- Taxa de Mutação para Habilitação de Conexões:

enabled_mutate_rate = 0.01

A taxa de mutação para a habilitação de conexões (`enabled_mutate_rate`) desempenhou um papel vital na exploração do espaço de soluções. Um ajuste cuidadoso dessa taxa resultou em uma maior diversidade de arquiteturas de rede, contribuindo para soluções mais adaptativas.

- Estratégia de Elitismo na Reprodução:

elitism = 10

O elitismo, representado pela variável `elitism`, mostrou-se benéfico para preservar os controladores mais aptos de uma geração para a próxima. Isso proporcionou uma base estável para a evolução, mantendo características eficazes presentes nos controladores líderes.

Essas modificações não apenas aceleraram a convergência durante o treinamento, mas também melhoraram a capacidade dos controladores evoluídos em se adaptar a nuances específicas de cada pista. A sintonia fina desses parâmetros demonstrou ser fundamental para o sucesso do algoritmo NEAT em ambientes de corrida autônoma.

VI. RESULTADOS

Os resultados desta pesquisa são exibidos de maneira individualizada para cada pista, oferecendo insights sobre o desempenho e a eficácia dos controladores evoluídos ao longo de 100 gerações. Esta análise detalhada permite identificar padrões de aprendizado e estratégias adotadas



pelos controladores em resposta aos desafios específicos impostos por cada pista inspirada na Fórmula 1.

Além disso, serão destacados detalhes específicos das escolhas feitas pelos controladores em diferentes momentos do processo evolutivo. Esses insights contribuem para uma compreensão mais aprofundada do processo de aprendizado e adaptação, permitindo uma análise crítica das estratégias que emergem como mais eficazes em cada contexto.

1) Pista Facil – Melbourne



Esta pista destaca-se pelas suas particularidades, apresentando predominantemente trechos retos intercalados com curvas suaves. A ausência de curvas acentuadas nesse percurso proporciona um ambiente singular para avaliar como os controladores evoluídos adaptam suas estratégias em resposta a uma configuração de pista mais linear.



Detalhes do gráfico Fitness

O gráfico de fitness ao longo das gerações revela padrões distintos no desempenho do algoritmo evolutivo. Observamos que, na 22ª geração, o "Best Fitness" exibe um

notável crescimento exponencial, indicando uma rápida evolução em direção a soluções mais otimizadas. No entanto, esse crescimento se estabiliza nas gerações subsequentes, sugerindo a convergência para uma solução ótima ou uma região de boa solução.

Enquanto isso, o "Average Fitness" mostra um crescimento gradual ao longo do tempo, com picos intermitentes em algumas gerações. Esses picos podem representar momentos em que a população atinge temporariamente soluções mais eficazes. O padrão de crescimento contínuo sugere uma melhoria consistente na aptidão média da população.

Essas tendências indicam uma fase inicial de descoberta rápida de soluções promissoras, seguida por uma fase de refinamento mais lento. A estabilização do "Best Fitness" no final sugere a possível convergência para uma solução robusta. Em conjunto, essas dinâmicas ilustram a eficácia do algoritmo em explorar e otimizar o espaço de soluções ao longo das gerações.

Detalhes Notáveis na Primeira Pista:

Durante a evolução dos controladores na primeira pista, observamos nuances intrigantes nas estratégias adotadas pelos controladores evoluídos, especialmente na terceira curva. Em alguns casos notáveis, a rede neural demonstrou habilidades notáveis ao encontrar posições estratégicas distintas, apresentando três cenários distintos.

A) Seguindo o Percurso Normal:

Em certas instâncias, os controladores evoluídos seguiram o percurso convencional, navegando pela terceira curva de maneira consistente com o design da pista. Essa abordagem destaca a capacidade da rede neural de interpretar e reagir adequadamente a condições de curvas mais suaves.

B) Volta de 90 Graus e Percurso Reverso:

Em outras situações, a rede neural demonstrou uma surpreendente flexibilidade ao posicionar o carro de forma a realizar uma volta de 90 graus na terceira curva. Após essa manobra, o veículo prosseguiu de maneira eficaz no percurso oposto. Essa estratégia demonstra a capacidade de adaptação da rede neural para enfrentar situações desafiadoras.



C) Posicionamento Estratégico e Parada:

Em casos menos convencionais, a rede neural encontrou posições estratégicas na terceira curva, onde o veículo conseguia permanecer parado sem se destruir. Esse comportamento peculiar sugere uma exploração única da rede neural ao tentar otimizar a eficiência em condições desafiadoras.

2) Pista Media – Interlagos



Ao contrário da primeira pista, a notável pista de Interlagos apresenta uma combinação diversificada de trechos, incluindo curvas acentuadas e seções mais lineares. A presença de curvas acentuadas em Interlagos desafia os controladores evoluídos a ajustar suas estratégias para enfrentar mudanças abruptas na direção.



Detalhes dos gráficos

Na análise de ambos os gráficos, notamos um crescimento inicial nas primeiras gerações, indicando uma rápida descoberta de soluções mais promissoras. No entanto, à medida que as gerações progridem, observa-se uma estabilização, sugerindo a possível convergência para soluções ótimas ou uma região de boas soluções.

Detalhes Notáveis na Segunda Pista:

Os detalhes notáveis da segunda pista revelam um padrão intrigante no desempenho da rede neural ao enfrentar as curvas desafiadoras. Nas primeiras curvas, a rede neural demonstra uma notável capacidade de aprendizado, sendo capaz de descobrir soluções eficazes em poucas gerações.


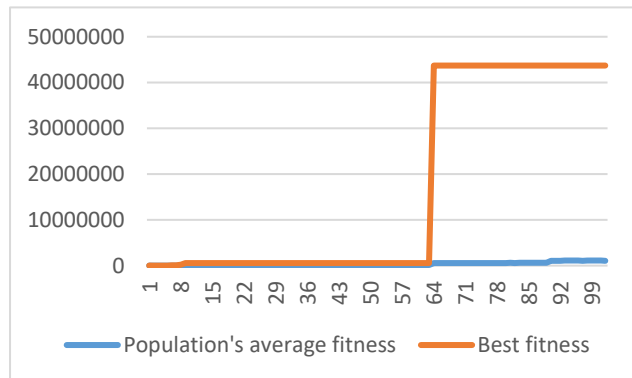
Isso sugere uma adaptação rápida às nuances iniciais da pista.

No entanto, a dinâmica muda significativamente na curva 13, também conhecida como "junção". A partir desta curva, observamos uma persistente dificuldade da rede neural em resolver o desafio apresentado, resultando em colisões consistentes ao longo de 100 gerações. Esse padrão indica um ponto crítico na pista, onde a complexidade ou peculiaridade do percurso representa um desafio significativo para o modelo.

3) Pista Difícil – Silverstone



Em comparação com a pista anterior, Silverstone apresenta curvas mais desafiadoras, adicionando uma camada extra de complexidade ao percurso. A presença de curvas acentuadas neste circuito intensifica a demanda sobre os controladores evoluídos, exigindo uma adaptabilidade superior para enfrentar mudanças mais pronunciadas de direção.



Detalhes Notáveis na Terceira Pista:

A pista de Silverstone revelou uma notável tendência de rápida evolução nos controladores evoluídos, alcançando a resolução da volta em menos de 20 gerações. Esse progresso inicial surpreendente sugere uma eficácia notável na adaptação dos controladores a esse ambiente específico.

Além disso, durante o processo evolutivo, observamos uma variedade de comportamentos emergentes. Alguns controladores demonstraram a capacidade de permanecer parados ou até mesmo dirigir para o lado inverso, destacando a diversidade de estratégias exploradas pela inteligência artificial.

No entanto, é interessante notar que a maioria dos controladores evoluídos convergiu para a resolução esperada do percurso, indicando uma assimilação eficaz dos desafios apresentados por Silverstone. À medida que as gerações avançavam, surpreendentemente, surgiram controladores capazes de resolver o percurso a uma velocidade superior, destacando uma otimização contínua e uma melhoria no desempenho dos controladores ao longo do tempo.

Conclusão

Em conclusão, este estudo revelou-se uma exploração fascinante da capacidade de adaptação de carros autônomos em diversas circunstâncias de corrida. A análise detalhada das pistas e o acompanhamento da evolução dos controladores destacaram não apenas a eficácia do algoritmo NEAT, mas também sua habilidade surpreendente em criar soluções inovadoras e não previstas. Observar o desenvolvimento autônomo desses controladores em resposta a desafios específicos enriqueceu nossa compreensão das potencialidades das redes neurais evolutivas em ambientes dinâmicos e imprevisíveis. Este estudo representa não apenas um avanço técnico, mas também uma revelação inspiradora da capacidade de aprendizado e adaptação das inteligências artificiais em cenários desafiadores.

Referencias

- 1- <https://medium.com/@evertongomede/neuroevolution-of-augmenting-topologies-neat-innovating-neural-network-architecture-evolution-bc5508527252>
- 2- https://www.youtube.com/watch?v=Cy155O5R1Oo&ab_channel=NeuralNine
- 3- <https://chat.openai.com>